

Datové sklady - struktura, důvody použití, rozdíl od běžné databáze, popis a rozdíl schémat Star/Snowflake, OLTP/OLAP význam

zdroje:

sešit Ka

https://en.wikipedia.org/wiki/Garbage_in,_garbage_out

Datové sklady - struktura, důvody použití, rozdíl od běžné databáze, popis a rozdíl schémat Star/Snowflake, OLTP/OLAP význam.....	1
Datový sklad.....	2
Důvody použití.....	2
Rozdíl: běžná databáze × datový sklad.....	2
Schémata datového skladu.....	2
Star.....	2
Příklad útulek.....	3
Galaxy.....	3
Příklad cykloservis.....	3
Snowflake.....	3
Příklad knihovna.....	4
Data Pipeline.....	4
0. Zdrojová data.....	4
- Transformace ELT/ETL.....	4
1. Vytvoření OLTP databáze.....	4
OLTP databáze.....	5
2. Business informace.....	5
3. OLAP systém.....	5
OLAP databáze.....	5

Datový sklad

- Datový sklad je speciální typ databáze určený pro analytické zpracování dat
- Slouží k:
 - získávání business informací
 - tvorbě přehledů, statistik a reportů
- Obsahuje převážně historická data
- Data se v něm:
 - většinou jen čtou
 - minimálně upravují

Důvody použití

- oddělení provozních a analytických dotazů
- zrychlení analytických dotazů
- možnost práce s historickými daty
- jednoduší tvorba reportů
- sjednocení dat z více zdrojů

Rozdíl: běžná databáze × datový sklad


- Běžná databáze (OLTP)
 - určena pro provoz systému
 - plně normalizovaná (3. NF)
 - splňuje všechna integritní omezení
 - vhodná pro:
 - denní transakce (INSERT, UPDATE, DELETE)
 - nevhodná pro:
 - složité analytické dotazy
 - dlouhodobé uchovávání dat
- Datový sklad (OLAP)
 - určen pro analýzu dat
 - nenormalizovaná struktura - denormalizace
 - optimalizován pro:
 - složité SELECT dotazy
 - obsahuje:
 - agregovaná a historická data

Schémata datového skladu

Star

- hvězdná databáze
- skládá se z jedné fact table, která obsahuje "měnitelné" a "spočítatelné" hodnoty "tabulka faktů" a odkazy na dimenzionální tabulky a dalších dimenzionálních tabulek - dim tables (číselníky) obsahující informace: kdo, kde, kdy, co


Příklad útulek



Galaxy

- obsahuje více fact tabulek


Příklad cykloservis



Snowflake

- potřeba, aby dim tabulky byly částečně normalizované

Příklad knihovna



Data Pipeline

- Data pipeline je proces, který zajišťuje tok dat od jejich zdrojů přes jejich zpracování a transformaci až do cílového systému určeného pro analýzu.
- GIGO (Garbage In, Garbage Out)
 - Princip, který říká, že pokud jsou vstupní data nekvalitní, budou nekvalitní i výsledky analýzy.
 - Data pipeline (zejména ETL proces) slouží k omezení dopadů GIGO pomocí čištění, kontroly a úpravy dat.

0. Zdrojová data

- uživatelské uložení dat (např.: excel, soubory)
- data jsou redundantní, obsahují chyby
- špatně se z nich získávají analytické informace

- Transformace ELT/ETL

- E - Extract
- L - Load
- T - Transform
- ELT - větší objem dat, dočasné tabulky
- ETL - menší objem dat, úprava napřed, přímo do nových tabulek

1. Vytvoření OLTP databáze

- OLTP (Online Transaction Processing)
 - způsob práce s daty
 - provádění denních transakcí
 - ukládání nových záznamů, úpravy existujících
 - rychlé dotazy pro provoz systému

OLTP databáze

- plně normalizovaná databáze (3. NF) , která splňuje všechna integritní omezení
- vhodné pro denní transakce
- není vhodné pro dlouhodobé uchovávání dat a získávání analytických informací (složité selecty)

2. Business informace

- definování analytických požadavků
- otázky typu
 - kdo?
 - kdy?
 - kde?
 - proč?

3. OLAP systém

- OLAP (Online Analytical Processing)
 - způsob práce s daty
 - získávat business informace
 - analyzovat historická a agregovaná data
 - tvořit přehledy, statistiky a reporty
- proces získávání business informací (analytické požadavky), pro které není původní OLTP databáze vhodná a proto se používá OLAP databáze

OLAP databáze

- nenormalizovaná struktura
- optimalizována pro SELECT / analytické dotazy
- obsahuje agregovaná a historická data
- používá schémata: Star, Snowflake, Galaxy